ANALISI SPETTRALE E CLASSIFICAZIONE DELLE SPECIE ARBOREE CON TECNICHE DI IMAGE PROCESSING E MACHINE LEARNING SU IMMAGINI SATELLITARI

Studenti: Saponaro Claudio, Mattiace Alessio

INTRODUZIONE

Negli ultimi anni, l'utilizzo delle immagini satellitari per l'analisi ambientale ha registrato un notevole incremento grazie ai progressi tecnologici nel campo del telerilevamento e della loro elaborazione; il nostro progetto si propone di approfondirne i concetti chiave ed applicarli ad uno specifico caso: quello della classificazione degli ulivi sul territorio Pugliese.

Il nostro studio, partendo proprio da immagini satellitari ad alta risoluzione, tenta di integrare delle tecniche di elaborazione con modelli di machine learning, offrendo una soluzione automatizzata per la classificazione delle specie arboree; tutti i codici e le funzioni utili ai nostri scopi, verranno scritti nel linguaggio di programmazione Matlab.

Gli obiettivi principali sono:

- Creare un database sufficientemente informativo e completo che, usando apposite features, permetta all'algoritmo di discriminare al meglio le varie specie di ulivi.
- Utilizzare diversi modelli di Machine Learning in grado di effettuare la vera e propria classificazione delle specie di alberi partendo dal dataset fornito.
- Confrontare l'efficacia dei modelli sopracitati, valutando le performance in termini di accuratezza, precisione e robustezza.

I risultati ottenuti potrebbero avere interessanti implicazioni per il monitoraggio ecologico e la gestione sostenibile delle risorse forestali, supportandone le decisioni nella pianificazione; inoltre, migliorerebbe la nostra capacità di monitorare la biodiversità, rilevare cambiamenti ecologici e identificare specie a rischio.

STATO DELL'ARTE

Come già accennato nell'introduzione, negli ultimi anni abbiamo assistito a notevoli progressi nel mondo del telerilevamento, con l'introduzione di nuove tecniche e tecnologie che hanno migliorato l'accuratezza e l'affidabilità con la quale effettuare stime sulla vegetazione.

Nell'analisi della letteratura scientifica abbiamo individuato diversi strumenti e componenti hardware adatti allo scatto di immagini multispettrali; ad esempio, in [1] vengono usate immagini multispettrali satellitari QUICKBIRD e IKONOS (tramite satellite IKONOS-2).

Un'alternativa potrebbe essere quella esaminata in [2] e [3] dove il detecting delle chiome non viene supportato da immagini ottenute da satellite, bensì da un UAV Italdron 4HSE EVO (drone multi-rotore) da un'altezza di circa 70 metri su cui sono montate diverse fotocamere:

- Fotocamera Multispettrale a cinque bande MicaSense RedEdge-M.
- Fotocamera Termica FLIR Vue Pro 640 (per la cattura di immagini termiche ad alta risoluzione).
- Fotocamera Visibile ad Alta Risoluzione Sony α7r.

Questo tipo di strumentazione è particolarmente efficace nel bilanciare la qualità delle immagini (risoluzione) e l'efficienza del volo (resa dei rilievi aerei), considerando le caratteristiche specifiche degli oliveti.

Per quanto riguarda invece la segmentazione delle chiome, diverse ricerche come [4], propongono di eseguire una trasformata di Hough circolare per via della loro forma simile ad una circonferenza, oppure utilizzare l'algoritmo di K-Means (dove le chiome rappresenteranno i clusters); risulta importante osservare che nel nostro caso non è stato necessario effettuare questo ulteriore step poiché ci sono state già fornite immagini con la segmentazione delle chiome da usare come maschera binaria sulle immagini satellitari.

Infine, [5] e [6] mostrano come utilizzare (e con quali risultati), gli algoritmi di Machine Learning utili alla classificazione delle specie di ulivi; di seguito una lista dei più citati in letteratura:

- Logistic Regression
- Support Vector Machines (SVM)
- Random Forest
- Linear Discriminant Analysis (LDA)
- Neural Networks

SEZIONE 1 – CREAZIONE DEL DATABASE

Il primo step è quello di ottenere un database da usare per la classificazione (opportunamente diviso in training e test set) il quale dovrà contenere, per ogni chioma, informazioni sul valore medio dei suoi pixel, per ognuna delle 47 bande; questo vuol dire avere uno spettro medio per ogni albero e poterlo usare in seguito, per la classificazione.

Materiale fornito

Per raggiungere il nostro scopo, citato nell'introduzione, possiamo contare sul seguente materiale:

- Due immagini satellitari multispettrali ad alta risoluzione con 47 differenti bande in formato .TIF di campagne Pugliesi contenenti ciascuna migliaia di chiome.

- Le rispettive maschere binarie contenenti tutte le chiome arboree già segmentate (da utilizzare per isolare l'ulivo dallo sfondo).

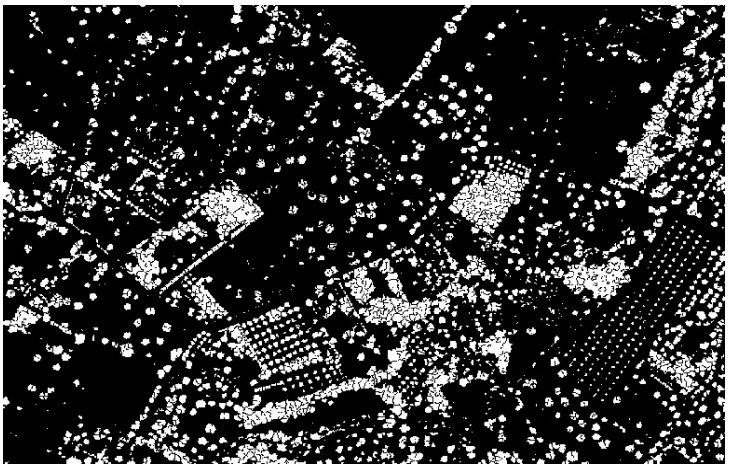

- I rispettivi database in formato Excel che includono alcune centinaia di alberi con la loro posizione in coordinate geografiche, già classificati con alcune delle tipologie di ulivo presenti sul territorio Pugliese (come "Leccino", "Ogliarola Barese", ecc.); i dati sono raccolti da operatori direttamente sul campo.

1	expolat	expolon	cult
2	40,9342177	17,2923034	Ogliarola barese
3	40,9342827	17,2921891	Ogliarola barese
4	40,9400784	17,2928914	Ogliarola barese
5	40,9402243	17,2936016	Ogliarola barese
6	40,9401585	17,2923973	Ogliarola barese
7	40,9396118	17,2914234	Altro
8	40,939656	17,2910401	Ogliarola barese
9	40,9402709	17,2920406	Ogliarola barese
10	40,9370405	17,284772	Ogliarola salentina
11	40,9372961	17,2857626	Ogliarola salentina

Importazione del Database

Per prima cosa abbiamo utilizzato il comando “readtable” di Matlab per leggere il database in formato Excel già fornito ed elimino le righe (o samples) che contengono dati mancanti, successivamente abbiamo assegnato delle variabili i valori di latitudine, longitudine e coltivazione.

Trasformazione in coordinate intrinseche

Per mappare le coordinate fornite dal database in punti dell’immagine, in cui vi è presente una chioma, trasformiamo le coordinate geografiche in coordinate intrinseche dell’immagine georeferenziata: tale operazione viene eseguita effettuando una proiezione tramite il comando “worldToIntrinsic”.

Ora abbiamo una matrice “points” contenente le coordinate delle chiome presenti e classificate nel nostro database; di seguito una visualizzazione della loro distribuzione rispetto al totale degli alberi presenti in un crop:

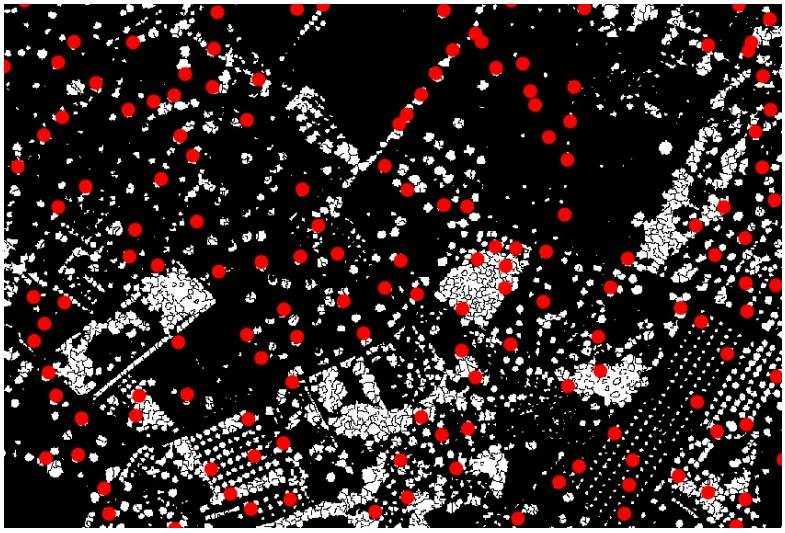

OSSERVAZIONE : Essendo un database costruito tramite dati ottenuti in modo manuale da operatori sul campo, le coordinate di alcuni alberi risultano non coincidenti con una specifica chioma nell’immagine, bensì sono sullo sfondo: in questi casi il data sample andrà perduto e la chioma non sarà presente nel dataset atto alla classificazione degli ulivi.

ID chioma univoco

Per trattare ogni chioma della nostra immagine in modo univoco, necessitiamo di un ID da assegnare ad ognuna di esse; quindi, dopo aver importato la maschera binaria andiamo ad usare il comando Matlab “bwlabel” che va ad etichettare ogni cluster dell’immagine segmentata ottenendo una matrice “L” con valore ‘0’ per le celle dello sfondo e un ID numerico per le celle dove sono presenti ulivi; inoltre, in “num” avremo il numero totale di essi che è nell’ordine delle migliaia.

Successivamente eseguo un semplice ciclo for per tener conto, in un vettore chiamato “id_chiome_db”, degli ID dei soli ulivi georeferenziati nel Database (e quindi utili alla classificazione).

Calcolo spettro medio

A questo punto, il nostro intento è quello di creare una matrice con 47 colonne e tante righe quanti sono gli alberi, in modo da contenere, per ogni riga (corrispondente alla singola chioma), lo spettro medio.

Per prima cosa, quindi, importiamo l'immagine multispettrale a 47 bande su cui effettuare le varie elaborazioni.

Successivamente creiamo un ciclo (for) che scorre tutte le chiome del nostro database in base al loro ID e, per ognuna delle 47 bande, andiamo per prima cosa a 'mascherare' l'immagine multispettrale, eliminando lo sfondo.

Di seguito viene fornita una visualizzazione del risultato di tale operazione.

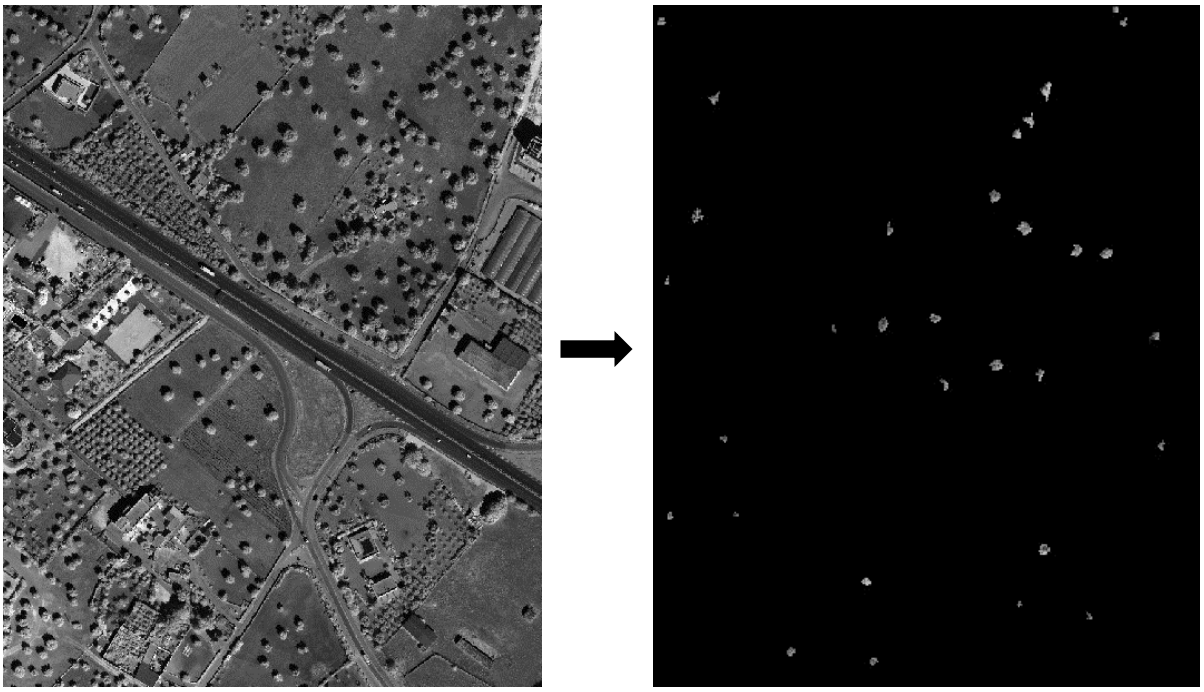

Poi, andiamo a calcolare l'array "Values" che contiene tutti i valori dei pixel di una singola chioma per una specifica banda, basandoci su questo risultato, andremo a ricavare il valore medio eliminando gli outliers.

OSSERVAZIONE: Consideriamo outliers tutti i valori che si allontanano dalla media più di una certa soglia (nel nostro caso la soglia è due volte la deviazione standard).

A questo punto utilizzeremo questo valore medio per riempire la cella (i, banda) della matrice "Firma_spettrale_media" dove "i" è la specifica chioma.

Aggiornamento del Database

Per concludere il nostro lavoro di creazione del database, da utilizzare per il successivo step ovvero classificazione delle specie arboree, vogliamo esportare partendo da Matlab un file Excel che contenga, oltre alle informazioni di latitudine, longitudine e coltivazione, anche lo spettro medio delle chiome e un ID univoco in modo tale da ottenere un file strutturato in questo modo:

	A	B	C	D	...	AX	AY
1	id_chioma	expolat	expolon	band_1		band_47	cult
2	5430	40.9551	17.2185	0.025879		0.45654	Ogliarola barese
3	3403	40.9528	17.2156	0.033464		0.38092	Leccino
4	964	40.9564	17.2124	0.034787		0.38367	Ogliarola barese
5	1435	40.9555	17.2131	0.036518		0.35798	Ogliarola barese
6	2952	40.9556	17.215	0.019335		0.38693	Ogliarola barese
7	5536	40.9526	17.2186	0.037703		0.46179	Ogliarola barese
8	4948	40.9526	17.2179	0.036161		0.51317	Ogliarola barese
9	4892	40.9529	17.2178	0.041245		0.42409	Ogliarola barese
10	4020	40.9577	17.2168	0.039686		0.47016	Altro
11	1745	40.958	17.2135	0.038708		0.37699	Altro
12	4196	40.9568	17.2171	0.03798		0.36169	Altro
13	3044	40.9522	17.2151	0.032143		0.42965	Altro
14	152	40.9524	17.2108	0.033527		0.43749	Altro

Tale operazione è stata effettuata concatenando orizzontalmente i vari vettori contenenti le informazioni (rispettivamente ID, latitudine, longitudine, banda 1, banda 2, …, banda 47, coltivazione) e associando i dati alle rispettive labels con “array2table”; infine usiamo il comando “writetable” per esportare la tabella creata in un file Excel nella directory corrente.

SEZIONE 2 – MODELLI DI CLASSIFICAZIONE

Dopo aver concluso la sezione relativa alla creazione della tabella, partendo dalle coordinate di latitudine, longitudine e coltura degli ulivi, risulta necessario classificarli utilizzando appositi algoritmi di apprendimento automatico.

A tal proposito sono stati scelti e utilizzati tre algoritmi per effettuare la classificazione:

1. SVM (Support Vector Machine)
2. RF (Random Forest)
3. LDA (Linear Discriminant Analysis)

Prima di spiegare in modo dettagliato il funzionamento e la logica di ognuno di questi algoritmi e, quindi, passare all'applicazione degli stessi sono stati effettuati dei passaggi preliminari di preprocessing del dataset a disposizione:

- Suddivisione del dataset in input (X) e output (Y).
- Normalizzazione di X usando la z-score normalization.
- Partizione del dataset, usando la strategia di 'Holdout', la quale prevede la suddivisione, in una singola istanza, considerando l'80% dei data points come training set e il restante 20% come test set (preservando la proporzione tra le varie classi usando la stratificazione).

Di seguito viene fornita una spiegazione del funzionamento dei tre modelli in questione:

SVM

Tale algoritmo è descritto nel dettaglio nel paper [7].

In estrema sintesi l'idea proposta nel paper è quella di rappresentare i dati in uno spazio di dimensione pari al numero delle features e provare a classificarli trovando un iperpiano separatore che massimizzi la distanza tra le varie classi di dati; questa distanza è delimitata dai margini: linee parallele all'iperpiano.

Se i dati sono linearmente separabili, siamo in grado di trovare un iperpiano che permette di classificare samples (senza l'utilizzo di funzioni di kernel), in caso contrario potremmo usare dei soft margins oppure il Kernel Trick (dove si proiettano i dati in uno spazio a dimensione più alta prima di essere 'separati').

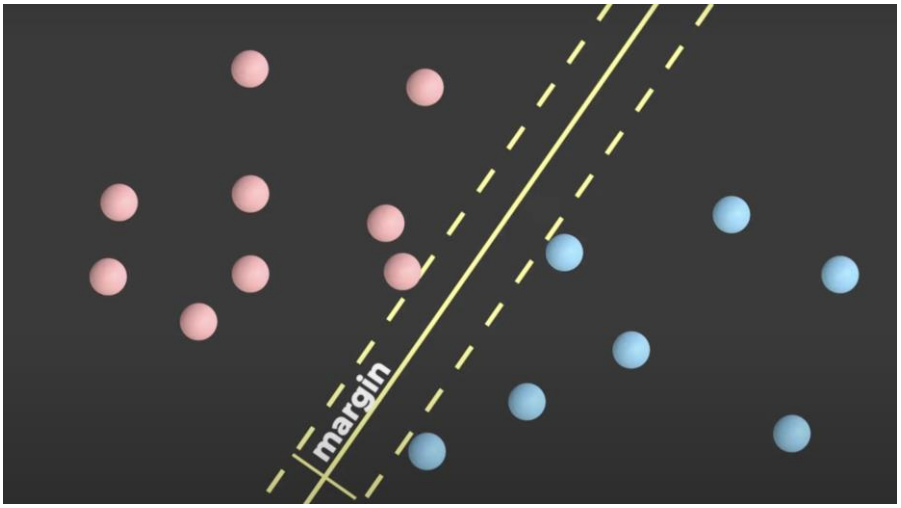

Tale figura mostra l'idea dell'algoritmo, possiamo visualizzare i vari dati appartenenti a due diverse classi (pallini rossi e blu), l'iperpiano separatore (linea gialla continua), i margini (linee gialle tratteggiate) e i vettori di supporto (pallino rosso e pallino blu giacenti sui margini).

Tale algoritmo è stato implementato in due varianti utilizzando la libreria offerta da Matlab: quello tradizionale senza l'utilizzo di funzioni di kernel, e l'SVM che sfrutta il kernel trick (per la precisione il kernel gaussiano).

Random Forest

Il secondo modello utilizzato è stato il Random Forest che rappresenta una generalizzazione del semplice classification tree.

Nell'algoritmo random forest vengono generati più alberi di classificazione ciò permette di limitare l'overfitting, (ovvero l'incapacità di generalizzare la previsione su nuovi dati sconosciuti al modello) al tal proposito l'algoritmo prende il nome di 'forest'.

Il termine 'random' deriva dal fatto che i 'bootstrap' datasets (ovvero i dataset costruiti a partire dal dataset originale), utilizzati per l'addestramento di ciascun albero di classificazione, vengono ottenuti in modo casuale effettuando un random sampling con reinserimento dal dataset originale.

I dati non presenti nel bootstrap dataset, ma presenti nel dataset originale, vengono utilizzati come validazione dall'albero di classificazione addestrato sul bootstrap corrente.

id	x_0	x_1	x_2	x_3	x_4	y
0	4.3	4.9	4.1	4.7	5.5	0
1	3.9	6.1	5.9	5.5	5.9	0
2	2.7	4.8	4.1	5.0	5.6	0
3	6.6	4.4	4.5	3.9	5.9	1
4	6.5	2.9	4.7	4.6	6.1	1
5	2.7	6.7	4.2	5.3	4.8	1

id
2
0
2
4
5
5

x_0, x_1

id
2
1
3
1
4
4

x_2, x_3

id
4
1
3
0
0
2

x_2, x_4

id
3
3
2
5
1
2

x_1, x_3

Tale figura chiarisce il processo di creazione dei bootstrap datasets su cui sono addestrati i vari alberi di classificazione.

Tale algoritmo viene dettagliatamente spiegato in [8].

Il numero di alberi di classificazione da utilizzare per creare la foresta casuale viene scelta a priori dall'utente mediante cross-validation per evidenziare la configurazione ottimale della classificazione finale; tuttavia, tale approccio non è stato utilizzato nel nostro codice poiché abbiamo utilizzato, come già spiegato nella fase di preprocessing, la tecnica del Holdout.

LDA

Tale algoritmo è stato teorizzato ed è spiegato nel dettaglio in [9].

A differenza dei precedenti algoritmi LDA si concentra sulla ricerca di un nuovo piano, dimensionalmente inferiore rispetto a quello iniziale, in cui risulta più semplice effettuare la classificazione; il termine 'linear' fa riferimento al tipo di classificatore che separa le classi (esso è lineare esattamente come nel SVM senza l'uso del kernel trick), tale classificatore assume che le matrici di covarianze siano le medesime per ogni classe.

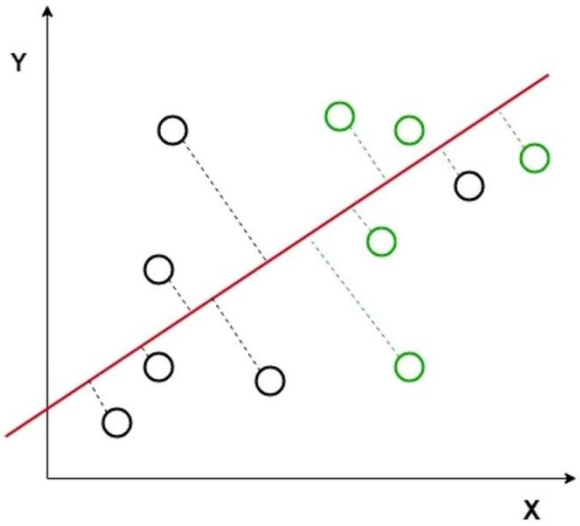

Il termine 'discriminant' fa proprio riferimento alla funzione discriminante utilizzata per la risoluzione dell'algoritmo, che è la modalità con cui esso cerca di trovare una combinazione lineare delle caratteristiche che massimizzi la separazione tra le classi; questo viene fatto massimizzando la varianza interclasse e minimizzando la varianza intraclasse.

Noi abbiamo utilizzato tre varianti:

- discriminante lineare (metodo standard che assume che la variabilità dei dati all'interno di ciascuna classe sia uguale in ogni direzione).
- discriminante diagonale (in cui viene assunto che la matrice di covarianza delle classi sia diagonale).
- discriminante pseudolineare che si colloca come compromesso degli approcci precedenti.

RISULTATI

Per concludere il nostro lavoro, abbiamo valutato l'output (o predizioni) dei modelli precedentemente descritti con alcune metriche per la classificazione:

Accuracy: proporzione tra previsioni corrette sul totale delle previsioni.

Precision: proporzione tra veri positivi su tutti i casi che il modello ritiene positivi - ci suggerisce quanto il modello sia in grado di non etichettare positive le classi negative.

Recall: proporzione tra i dati classificati correttamente positivi e tutti i dati realmente positivi - ci suggerisce quanto il modello sia in grado di classificare le istanze positive.

F1-Score: formula che tiene in considerazione sia recall che precision in una sorta di media armonica.

Di seguito vi sono riportati i risultati per ogni modello:

OSSERVAZIONE - i valori NaN, all'interno delle metriche, corrispondono ad un'assenza della specifica classe tra i data samples nel test set utilizzato, di conseguenza il modello non riesce ad usarle per la classificazione.

OSSERVAZIONE – ogni classe avrà un proprio valore di precision, recall ed F1-Score, mentre l'accuracy è univoca per ogni classe.

SVM Lineare

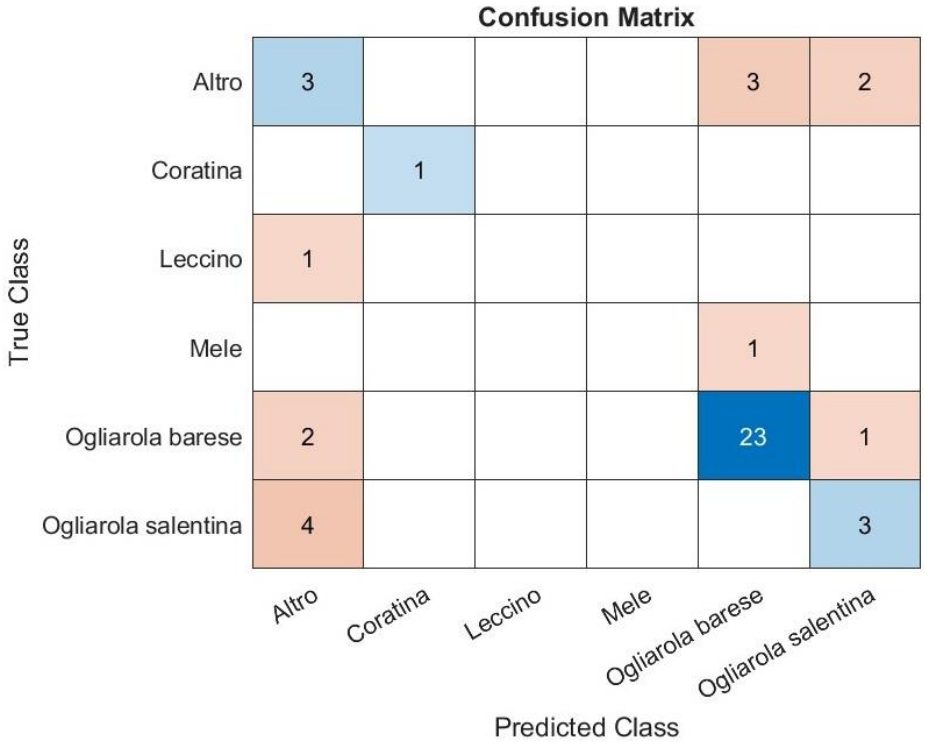


```
Accuracy: 68.18%
----------------
Precision: 0.30
Precision: 1.00
Precision: NaN
Precision: NaN
Precision: 0.85
Precision: 0.50
----------------
Recall: 0.38
Recall: 1.00
Recall: 0.00
Recall: 0.00
Recall: 0.88
Recall: 0.43
----------------
F1-Score: 0.33
F1-Score: 1.00
F1-Score: NaN
F1-Score: NaN
F1-Score: 0.87
F1-Score: 0.46
```

SVM con Kernel gaussiano

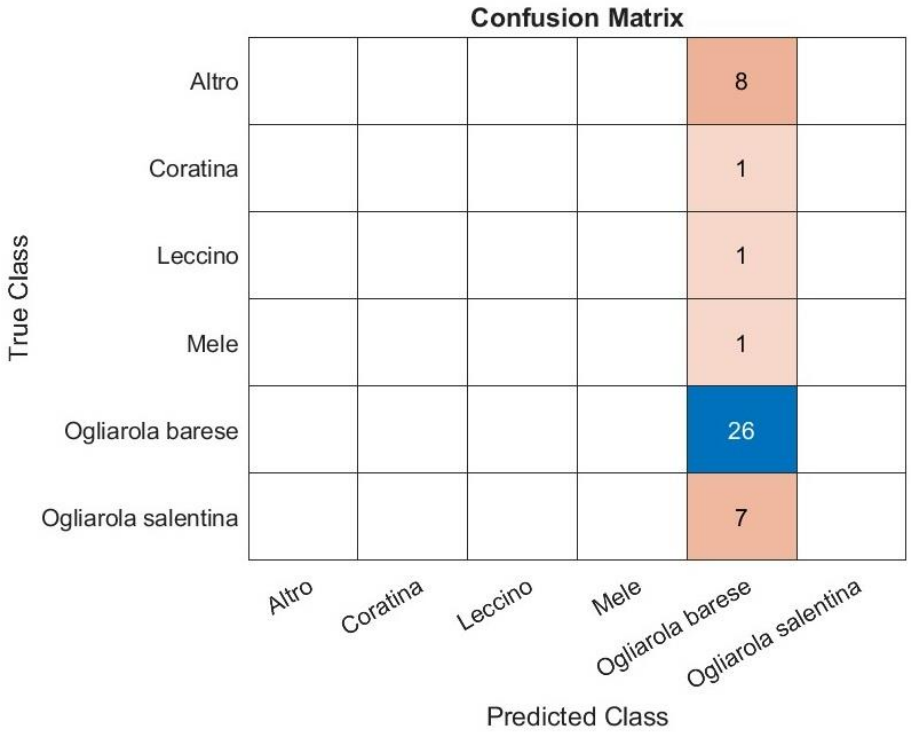


```
Accuracy: 59.09%
----------------
Precision: NaN
Precision: NaN
Precision: NaN
Precision: NaN
Precision: 0.59
Precision: NaN
----------------
Recall: 0.00
Recall: 0.00
Recall: 0.00
Recall: 0.00
Recall: 1.00
Recall: 0.00
----------------
F1-Score: NaN
F1-Score: NaN
F1-Score: NaN
F1-Score: NaN
F1-Score: 0.74
F1-Score: NaN
```

Random Forest

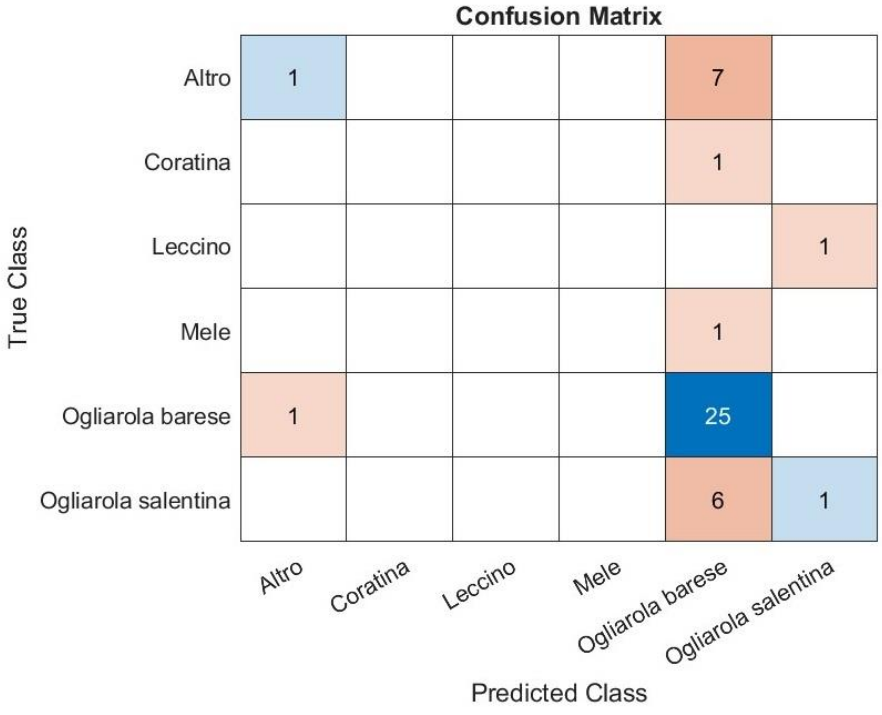


```
Accuracy: 61.36%
----------------
Precision: 0.50
Precision: NaN
Precision: NaN
Precision: NaN
Precision: 0.62
Precision: 0.50
----------------
Recall: 0.12
Recall: 0.00
Recall: 0.00
Recall: 0.00
Recall: 0.96
Recall: 0.14
----------------
F1-Score: 0.20
F1-Score: NaN
F1-Score: NaN
F1-Score: NaN
F1-Score: 0.76
F1-Score: 0.22
```

LDA con Discriminant Type linear

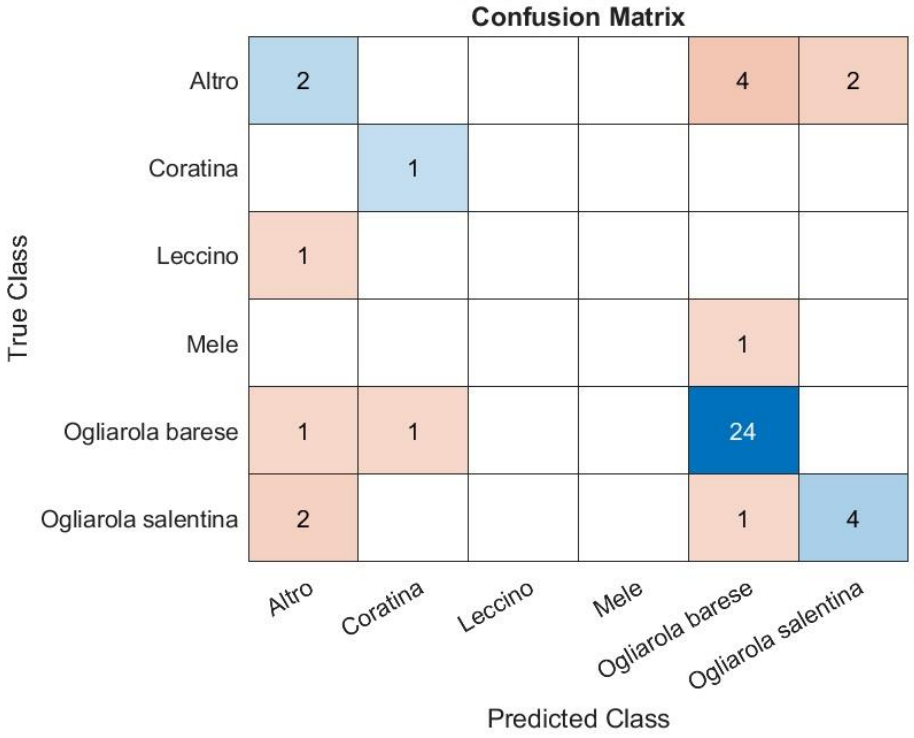


```
Accuracy: 70.45%
----------------
Precision: 0.33
Precision: 0.50
Precision: NaN
Precision: NaN
Precision: 0.80
Precision: 0.67
----------------
Recall: 0.25
Recall: 1.00
Recall: 0.00
Recall: 0.00
Recall: 0.92
Recall: 0.57
----------------
F1-Score: 0.29
F1-Score: 0.67
F1-Score: NaN
F1-Score: NaN
F1-Score: 0.86
F1-Score: 0.62
```

LDA con Discriminant Type diaglinear

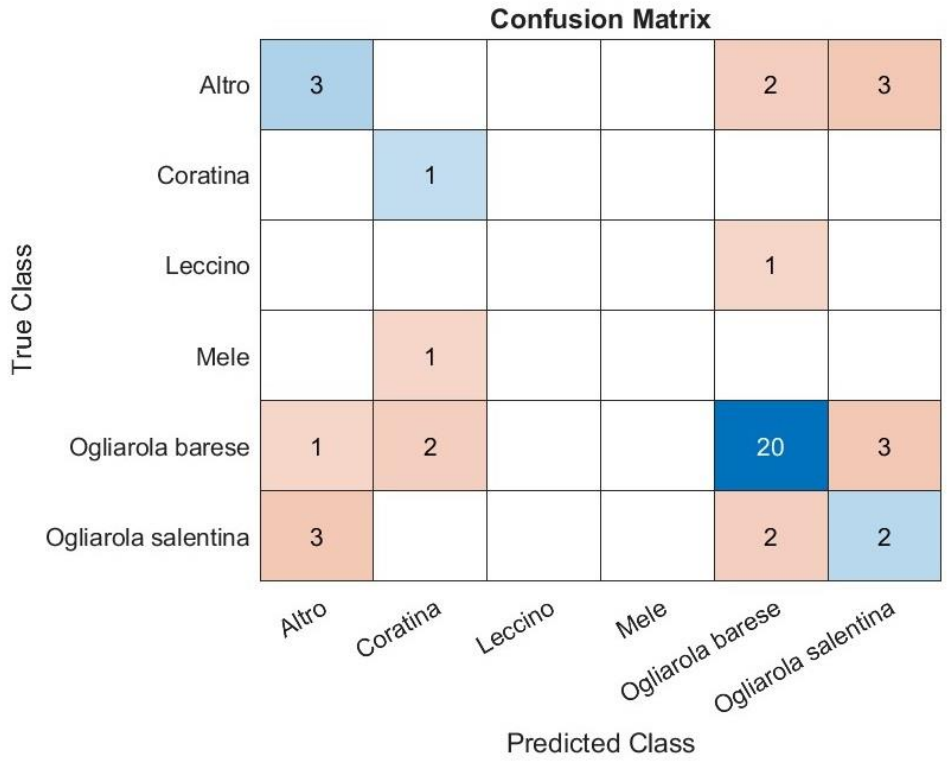


```
Accuracy: 59.09%
----------------
Precision: 0.43
Precision: 0.25
Precision: NaN
Precision: NaN
Precision: 0.80
Precision: 0.25
----------------
Recall: 0.38
Recall: 1.00
Recall: 0.00
Recall: 0.00
Recall: 0.77
Recall: 0.29
----------------
F1-Score: 0.40
F1-Score: 0.40
F1-Score: NaN
F1-Score: NaN
F1-Score: 0.78
F1-Score: 0.27
```

LDA con Discriminant Type pseudolinear

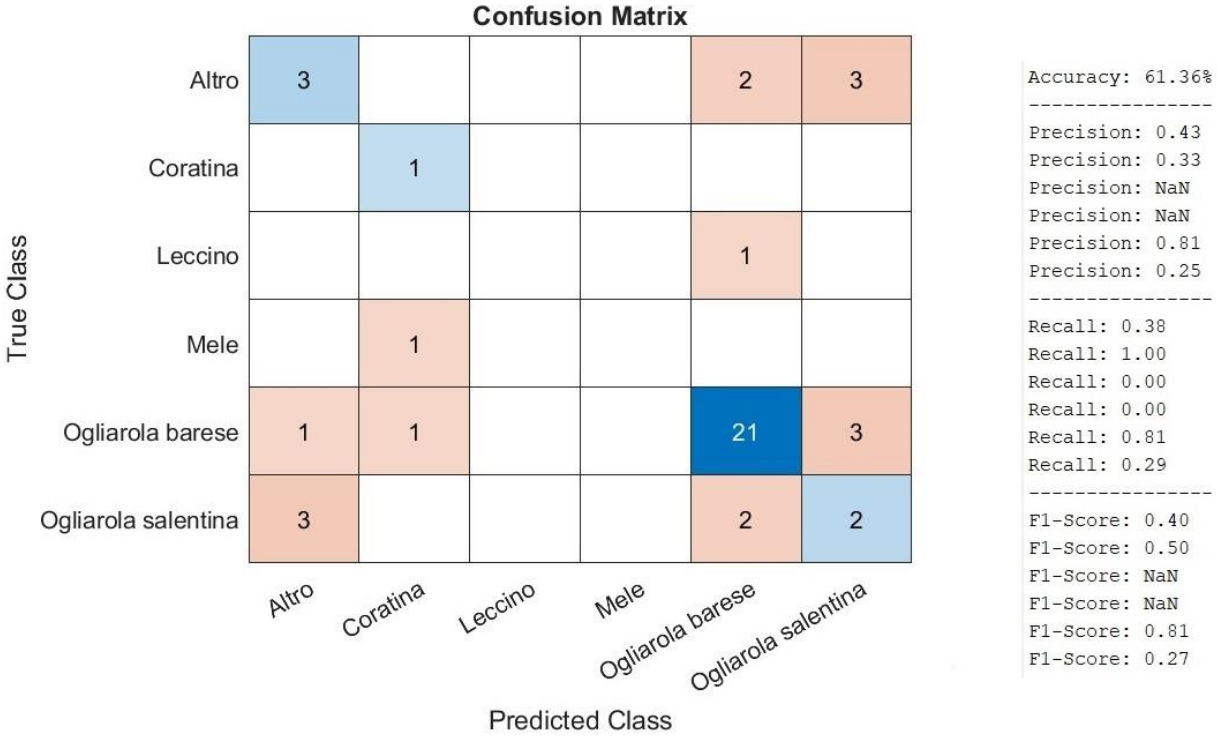

Notiamo, per concludere, che i modelli migliori, secondo le metriche utilizzate, sono stati SVM con Kernel lineare e LDA con discriminant type lineare capaci di che raggiungere livelli di accuracy vicini al 70%, tutti gli altri da noi testati invece, come il Random forest, performano peggio raggiungendo un'accuracy del 60%; il peggiore risulta essere l'SVM con kernel gaussiano poiché non è in grado di classificare correttamente nessuno degli ulivi all'infuori dell'Ogliarola barese.

RIFERIMENTI

[1] M. Waleed, T. -W. Um, A. Khan and Z. Ahmad, "An Automated Method for Detection and Enumeration of Olive Trees Through Remote Sensing," in IEEE Access, vol. 8, pp. 108592-108601, 2020, doi: 10.1109/ACCESS.2020.2999078.

[2] «Sensors | Free Full-Text | Fast Detection of Olive Trees Affected by Xylella Fastidiosa from UAVs Using Multispectral Imaging». Consultato: 8 marzo 2024. [Online]. Disponibile su: https://www.mdpi.com/1424-8220/20/17/4915

[3] F. Adamo, F. Attivissimo, A. Di Nisio, M. A. Ragolia and M. Scarpetta, "A New Processing Method to Segment Olive Trees and Detect Xylella Fastidiosa in UAVs Multispectral Images," 2021 IEEE International Instrumentation and Measurement Technology Conference (I2MTC), Glasgow, United Kingdom, 2021, pp. 1-6, doi: 10.1109/I2MTC50364.2021.9459835.

[4] A. Khan et al., "Remote Sensing: An Automated Methodology for Olive Tree Detection and Counting in Satellite Images," in IEEE Access, vol. 6, pp. 77816-77828, 2018, doi: 10.1109/ACCESS.2018.2884199.

[5] M. S. Mandava, D. Jadhav and R. R. Naik, "Fault classification using SVM," 2015 IEEE International Circuits and Systems Symposium (ICSyS), Langkawi, Malaysia, 2015, pp. 17-21, doi: 10.1109/CircuitsAndSystems.2015.7394056.

[6] G. Ramat et al, "Mapping of olivetrees using Sentinel-2 and Sentinel-1 images: an assessation of pixel-based analyses," 2023 IEEE International Workshop on Metrology for Agriculture and Forestry (MetroAgriFor), Pisa, Italia, 2023, pp. 263-267, doi: 10.1109/MetroAgriFor58484.2023.10424313.

[7] M. A. Hearst, S. T. Dumais, E. Osuna, J. Platt and B. Scholkopf, "Support vector machines," in IEEE Intelligent Systems and their Applications, vol. 13, no. 4, pp. 18-28, July-Aug. 1998, doi: 10.1109/5254.708428.

[8] Cutler, Adele & Cutler, David & Stevens, John. (2011). Random Forests. 10.1007/978-1-4419-9326-7_5.

[9] Fisher, R.A. (1936) The Use of Multiple Measurements in Taxonomic Problems. Annals of Eugenics, 7, 179-188. http://dx.doi.org/10.1111/j.1469-1809.1936.tb02137.x